



同等单次样本预算
本地仍略低于论文

a




工程集成点更高
但累计使用了更多样本

b



内部改进点估计均为正
但部分区间仍跨0

c



注：a/b 的论文列为原文 F1；本地使用 Macro-F1。论文未明确 F1 averaging，因此属于近似口径比较。