

提升数据与原论文

逐项对比

RTX 4060 本地实验：DAPT、R-Drop 与 Qwen 选择性复核

对照论文

Zhu et al., *Analyzing bullet chats for recommendation intent identification: Dataset and method*, *Artificial Intelligence* 355 (2026) 104528

核心数据集

RecDY；论文固定测试集，本地协议对齐测试 $n = 9,069$

本地环境

NVIDIA GeForce RTX 4060 Laptop GPU，8 GB 显存

主交付格式

XeLaTeX 源文件与编译 PDF

报告日期

2026 年 7 月 19 日

一句话结论

在固定同一份 70-shot/类训练集和验证集后，DAPT+R-Drop 五模型同标签集成为 80.60%；再由本地 Qwen3:8B Q4_K_M 仅复核低置信样本，完整测试集 Macro-F1 达到 80.94%。大模型相对本地学生带来 +0.34pp 的正向点估计，相对论文 Table 5 的 79.23% 为描述性 +1.71 pp；但逐行与直播间聚类 bootstrap 区间均跨 0，因此不称统计显著。

目录

1	结论先行	1
2	原论文位置索引与本地对应	2
3	主对比：原论文 §6.5 / Table 5 / p.14	3
4	严格同标注预算改进：DAPT + R-Drop	6
5	必须使用大模型的完整改进：Qwen 选择性证据复核	8
6	内部提升：对应 §5.3、§6.6 Fig.6，但协议不同	12
7	前期小样本门控探索：对应 §6.7 / Table 6	14
8	效率：对应 §6.10 / Table 9 / p.17	15
9	如何通俗解释这次提升	16
10	可信度、限制与下一步	18
11	证据文件索引	20

1 结论先行

本项目没有完整复现 SPT-RII 的 soft prompt、BiLSTM prompt interaction、动态 verbalizer 和词性/语义锚更新，而是在 RTX 4060 8 GB 条件下建立了一条可运行的替代路线。严格实验锁定同一份 70-shot/类人工标注，先用发布训练分区的无标签弹幕做领域自适应掩码语言建模 (DAPT)，再采用 R-Drop 抑制少样本微调波动，并对五个共享同一标签集的初始化做等权概率平均。最后，冻结的 Qwen3:8B 不再全量生成解释或充当独立分类器，而只对学生模型的低置信样本进行证据约束复核。

表 1 结果层级与主要判断。严格同预算行是本轮新增主结果；跨论文差值仍受 F1 定义差异限制。

比较层级	实验	本地结果	变化	判断
历史协议对齐	70-shot 独立运行	78.00 ± 0.14%	−1.23 pp	三个种子同时改变抽样与初始化
历史工程集成	70-shot 三种子概率集成	81.65%	+2.42 pp	训练标签并集 420 条
严格同预算	DAPT+R-Drop, 固定 split 五初始化	80.01 ± 0.62%	+0.78 pp	单成员均值已越过论文报告点
严格同预算集成	同一标签集五模型概率平均	80.60%	+1.37 pp	人工标签不变，模型计算约 5 倍
严格大模型增强	上述集成 + Qwen 选择性复核	80.94%	+1.71 pp	相对本地 +0.34 pp; CI 跨 0
内部改进	TF-IDF, 1,000 训练	82.29 → 83.82%	+1.53 pp	CI 跨 0
内部改进	RoBERTa, 1,000 训练	87.19 ± 0.53 → 87.63 ± 0.29%	+0.43 pp	三个种子均为正
探索性改进	不确定性门控	82.29 → 83.71%	+1.42 pp	95% CI [−2.61, +5.37]

指标口径

原论文只写 F1/Prec./Rec., 没有说明 macro、micro 或 weighted averaging; 本地使用 scikit-learn Macro-F1/Macro-Precision/Macro-Recall。因此跨论文差值属于近似口径对照，不声称指标定义完全等价。论文正文也未明说 50/60/70-shot 是“每类”还是“总数”；本地依据公开实现按每类 shot 执行。

严格 2×2 消融表明，主要增益来自 DAPT：基础 CE 集成为 79.15%，DAPT+CE 提高到 80.45%；单独加入 R-Drop 仅为 79.38%，两者结合达到 80.60%。在此基础上，Qwen 复核使点估计进一步达到 80.94%。旧三种子集成仍保留为历史工程点，但因各成员重新抽样而扩大累计标注覆盖，不能替代新的同标签预算证据。

2 原论文位置索引与本地对应

PDF 页码与论文印刷页码一致。表 2 按“原论文位置 → 原文作用 → 本地对应 → 可比性”组织，读者可直接回到原文核验。

表 2 原论文与本地实验的位置级映射。S/T 编号来自 paper_reader/source_map.json。

主题	原论文精确位置	原文内容	本地对应与关系
问题动机	§5.1, p.8, S0064	短弹幕依赖上下文；流式语义锚会被稀释	上下文重构与解释增强； 概念对应
解释生成	§5.2–5.3, pp.9–10, Fig.5, S0066–S0073	LLM 在前 20 条滑窗内做语境语义重构	保留 20 条上下文，但 Qwen 改为低置信样本复核器； 概念对应
提示学习	§5.4, p.10, S0073/S0077	Soft prompt + BiLSTM 交互	用 RoBERTa/TF-IDF 替代； 未复现
动态标签词	§5.5–5.6, pp.10–12, S0080–S0101	POS 候选、语义距离、half-life=10、Top- <i>k</i> 更新	验证集融合/门控替代； 未复现
数据协议	§6.1, p.12, S0109	各平台 70% train / 30% test；测试集只作最终评估	RecDY 固定 test <i>n</i> = 9,069； 协议对齐
训练设置	§6.3–6.4, p.13, S0113	50/60/70-shot；验证集等大；3 次重复；RTX 4090	每类 shot；种子 100/101/102；RTX 4060；近似对齐
主结果	§6.5, Table 5, p.14, T001	RecDY SPT-R11 F1 为 77.84/78.92/79.23	严格固定 split、同标签集成与选择性 Qwen 完整方法； 协议对齐
消融	§6.6, Fig.6, p.15, S0116/S0117	去解释 −4.3 pp；去更新 −2.8 pp	解释通道与 late fusion； 概念对应
大模型	§6.7, Table 6, p.16, S0117/S0118	Qwen3:8B 用 1,000 样本 PEFT 后独立分类	冻结 Qwen3:8B 只作检索增强、可拒答的难例复核；功能对照
效率	§6.10, Table 9, p.17, S0186/S0210	更换解释模型后的 F1 与时间	只路由 17.58% 测试样本，并报告本地推理记录； 描述性对照
参数敏感性	§6.12, Fig.9, pp.19–20, S0264/S0266	窗口 0 → 20 提升，过大引入过噪	压缩上下文、验证集融合；设计依据
错误分析	§6.13, pp.20–21, S0266	隐式语义、上下文不足等错误	Qwen 改对 349 条、改错 299 条，净增 +50 条； 概念对应

未覆盖内容

本地没有复现 Table 7 的 BTD 外部数据、Table 8 的跨平台迁移、Table 10 的蒸馏、Table 11/Fig.8 的模板实验，以及 Fig.9 的完整参数扫描。它们只列入索引，不参与提升结论。

3 主对比：原论文 §6.5 / Table 5 / p.14

可比性等级：A-

同为 RecDY 固定测试集 $n = 9,069$ ，训练/验证按 50、60、70-shot 抽样，并报告 3 次独立运行。差异是模型结构、硬件和指标定义不完全相同；因此称“协议对齐的描述性比较”，不称 SPT-RII 完整复现。

Y. Zhu, Q. Han, Y. Yuan et al.

Artificial Intelligence 355 (2026) 104528

Table 5
Experimental results across four platforms and all baselines under varying data conditions. All the results are presented as average value $\pm$ SD (%). Bold indicates the best result, and underline indicates the second-best result.

Platform	Method	200/200/50/0/50				400/400/60/0/60				800/800/70/0/70			
		Acc.	Prec.	Rec.	F1.	Acc.	Prec.	Rec.	F1.	Acc.	Prec.	Rec.	F1.
RecDY	Text-CNN	65.14±0.48	63.67±0.08	63.73±0.47	63.61±0.26	68.18±0.59	68.05±0.77	68.90±0.83	67.77±0.66	70.89±0.13	70.99±0.18	71.98±0.19	70.58±0.13
	ADB	57.28±2.08	42.01±0.80	38.21±1.71	39.75±1.16	57.55±1.40	42.73±1.02	38.91±1.38	40.17±0.97	59.05±0.62	44.94±0.28	40.25±0.78	41.68±0.27
	SimSTC	63.13±0.05	63.52±3.22	56.72±1.38	53.82±3.00	64.39±0.47	67.08±1.91	57.36±1.06	53.88±2.38	65.32±0.05	66.15±0.24	59.17±0.11	57.31±0.22
	SHINE	68.15±0.96	67.39±1.79	63.24±0.41	63.24±0.27	69.63±0.62	70.25±0.81	64.10±0.74	63.97±0.83	70.25±0.80	72.10±1.90	64.34±0.57	64.09±0.58
	NC-HGAT	67.21±0.48	67.01±0.42	67.81±0.44	66.76±0.46	69.70±0.10	69.75±0.12	70.68±0.12	69.36±0.09	73.19±0.11	73.33±0.09	74.43±0.09	72.92±0.10
	GIFT	66.24±0.24	64.01±0.24	63.90±0.50	63.93±0.39	67.18±0.42	64.92±0.27	64.68±0.09	64.76±0.10	68.10±0.34	65.73±0.40	65.02±0.47	65.26±0.45
	BERT	57.73±1.31	52.48±1.12	51.70±1.12	49.16±3.67	70.53±1.04	69.18±0.94	69.18±1.29	69.12±1.12	71.61±2.09	71.90±1.02	72.56±0.88	71.17±1.69
	IntentBERT	63.82±0.15	65.85±0.17	63.82±0.15	62.51±0.16	62.18±0.15	63.83±0.18	62.18±0.15	60.86±0.16	62.00±0.15	63.30±0.17	62.00±0.15	60.73±0.16
	IntentBERT-MLM	63.52±0.14	65.41±0.16	63.52±0.14	62.29±0.15	65.86±0.15	67.36±0.16	65.86±0.15	64.85±0.15	65.02±0.16	66.73±0.18	65.02±0.16	63.77±0.17
	KPT	74.53±3.06	74.15±1.69	74.59±1.28	73.82±2.41	76.38±3.17	75.76±2.89	76.88±2.89	75.86±2.99	77.78±2.38	77.07±2.47	77.59±2.14	77.11±2.22
	KPT++	75.86±1.50	74.99±1.45	75.75±1.45	75.19±1.52	76.25±1.48	75.30±1.47	75.50±1.66	75.30±1.63	77.38±1.30	76.40±1.38	76.73±1.37	76.47±1.35
	P-tuning	76.66±2.30	75.70±2.56	75.53±3.17	75.49±2.81	78.25±1.77	77.72±1.66	78.10±1.53	77.82±1.76	79.94±1.72	79.09±1.77	79.47±1.93	79.18±1.72
	MSP	73.37±0.56	72.21±1.26	72.63±0.79	72.38±0.36	73.98±0.46	73.74±0.93	74.86±0.63	73.61±0.38	74.95±1.62	74.16±1.25	75.08±1.71	74.35±1.58
	LLaMA3	61.74±0.24	59.66±0.21	59.46±0.25	59.54±0.25	61.74±0.24	59.66±0.21	59.46±0.25	59.54±0.25	61.74±0.24	59.66±0.21	59.46±0.25	59.54±0.25
RecKS	Deepseek-V3	67.93±0.09	69.71±0.03	70.28±0.05	67.88±0.08	67.93±0.09	69.71±0.03	70.28±0.05	67.88±0.08	67.93±0.09	69.71±0.03	70.28±0.05	67.88±0.08
	ChatGPT-4o	72.06±0.26	71.71±0.23	72.71±0.24	71.62±0.25	72.06±0.26	71.71±0.23	72.71±0.24	71.62±0.25	72.06±0.26	71.71±0.23	72.71±0.24	71.62±0.25
	FaithfulRAG	66.16±0.13	66.14±0.05	66.91±0.08	65.76±0.16	66.16±0.13	66.14±0.05	66.91±0.08	65.76±0.16	66.16±0.13	66.14±0.05	66.91±0.08	65.76±0.16
	SPT-RII(ours)	78.41±0.39	77.63±0.31	78.96±0.20	77.84±0.32	79.50±0.75	78.65±0.49	79.48±0.39	78.92±0.56	80.62±0.37	79.96±0.32	80.30±0.23	79.23±0.31
	Text-CNN	70.48±0.93	71.49±1.15	72.62±1.17	70.25±1.02	74.62±0.84	74.07±0.33	75.36±0.29	74.01±0.64	78.68±0.45	77.88±0.47	79.18±0.54	78.01±0.42
	ADB	62.34±3.91	44.02±2.26	41.18±2.50	42.35±2.47	68.41±0.48	49.68±0.08	45.12±0.34	47.24±0.18	67.49±0.35	50.60±0.80	44.47±0.46	47.29±0.56
	SimSTC	66.78±0.34	52.65±0.73	51.64±0.50	50.59±0.64	70.44±0.23	58.46±0.53	53.88±0.15	52.51±0.20	72.24±0.19	63.29±0.61	54.74±0.50	52.98±0.89

图 1 原论文 Table 5 的标题、表头与 RecDY 区域，来源：原论文 p.14。

3.1 F1 主结果

表 3 Table 5 核心 F1 对照。独立运行均值是主结果；集成列均为单个工程点，没有 SD。

shot/类	论文 SPT-RII F1±SD	本地独立均值 Macro-F1±SD	独立 差值	内容集成 单点	集成 差值	内容 + 字符 集成单点	融合 差值
50	77.84 ± 0.32	75.52 ± 1.67	-2.32	77.29	-0.55	77.29	-0.55
60	78.92 ± 0.56	77.00 ± 0.89	-1.92	78.86	-0.06	78.86	-0.06
70	79.23 ± 0.31	78.00 ± 0.14	-1.23	81.65	+2.42	81.85	+2.62

保持每次独立运行的 70-shot/类预算时，本地内容模型为 $78.00 \pm 0.14\%$ ，仍比论文 $79.23 \pm 0.31\%$ 低 1.23 pp。三模型内容概率集成达到 81.65%，相对论文报告点高 2.42 pp；再加入字符 TF-IDF 后为 81.85%，额外仅 +0.20 pp。

表 4 工程集成的累计标注覆盖。70-shot 集成整体看到 420 条训练样本，约 210/类。

每成员 shot/类	每成员训练总数	三成员训练并集	训练 + 验证总并集	内容集成点
50	100	299	592	77.29%
60	120	360	713	78.86%
70	140	420	824	81.65%

表述红线

旧三种子工程集成可以说“固定测试集上达到 81.65%”，但不能说它以同等累计标签预算超过论文，因为训练并集为 420 条。新的固定 split 实验可以说“所有成员共享同一 70/类训练标签，DAPT+R-Drop 集成为 80.60%，再加 Qwen 选择性复核达到 80.94%”；仍不能称为 SPT-RII 完整复现或同计算预算胜出。




图 2 固定 RecDY 测试集上的论文对齐比较。误差线为独立运行 SD；空心标记为单个集成点。

3.2 Table 5 四指标复核

表 5 原论文 Table 5 与本地结果的 Accuracy/Precision/Recall/F1 复核，单位为百分比。集成行是单点。

shot/类	方法	Accuracy	Precision	Recall	F1
50	论文 SPT-R11	78.41 ± 0.39	77.63 ± 0.31	78.96 ± 0.20	77.84 ± 0.32
50	本地独立均值	76.59 ± 2.37	76.11 ± 2.80	75.74 ± 1.03	75.52 ± 1.67
50	本地内容集成	78.21	77.17	77.44	77.29
60	论文 SPT-R11	79.50 ± 0.75	78.65 ± 0.49	79.48 ± 0.39	78.92 ± 0.56
60	本地独立均值	78.09 ± 0.42	77.21 ± 0.31	77.06 ± 1.44	77.00 ± 0.89
60	本地内容集成	79.94	79.06	78.69	78.86
70	论文 SPT-R11	80.62 ± 0.37	79.96 ± 0.32	80.30 ± 0.23	79.23 ± 0.31
70	本地独立均值	79.26 ± 0.52	78.63 ± 0.92	77.76 ± 0.58	78.00 ± 0.14
70	本地内容集成	82.70	82.13	81.29	81.65
70	严格固定 split 基线集成	79.71	78.86	79.83	79.15
70	严格 DAPT+R-Drop 同标签集成	81.55	80.73	80.48	80.60
70	上述集成 + Qwen 选择性复核	82.10	81.61	80.49	80.94

指标与论文内部不一致

论文表头为 Prec./Rec./F1，但 §6.4 未说明 averaging；本地三项采用宏平均。另有一处论文内部不一致：Table 5 的 RecDY 50-shot SPT-R11 F1 为 77.84 ± 0.32%，Table 6 同一标签写 78.32%。本文始终使用 Table 5 作为主参照。

4 严格同标注预算改进：DAPT + R-Drop

本轮新增协议

从发布训练分区中用固定种子 20260718 抽取每类 70 条训练和每类 70 条验证；五个成员共享完全相同的 140 条训练行与 140 条验证行，只改变初始化和 Dropout。训练签名为 f493253c...5ec7b，验证签名为 0725f080...8acd；完整测试集仍为 9,069 条，阈值固定为 0.5，测试标签在所有 checkpoint 选择完成后才加载。

4.1 改进方法与 4060 成本

DAPT 阶段只读取训练分区的 `row_id/content`，不读取人工标签、验证集或测试集。Chinese-RoBERTa 在 21,159 条无标签弹幕上进行 1 epoch 掩码语言建模，mask 比例 0.15，最大长度 64，有效 batch 32；耗时 214.1 s，PyTorch 峰值显存 2.42 GiB。监督阶段最大 15 epoch、early stopping patience 4、学习率 4×10^{-5} 、最大长度 128；R-Drop 使用两次 dropout 前向、对称 KL 权重 0.5 和 0.05 label smoothing。DAPT 只覆盖 embeddings/encoder，原始 pooler 被明确保留，加载键审计为 197 个 encoder 键、0 个 unexpected key。

表 6 固定同一标签集的 2×2 消融。单成员 SD 仅表示固定 split 下的初始化/Dropout 波动；集成是单点。“对论文”与“对基线”均为百分点。

方法	DAPT	R-Drop	单成员均值 ±SD	同标签集成	对论文	对基线
基础 RoBERTa + CE	否	否	77.61±1.44	79.15	-0.08	+0.00
DAPT RoBERTa + CE	是	否	79.23±1.07	80.45	+1.22	+1.30
基础 RoBERTa + R-Drop	否	是	77.77±1.12	79.38	+0.15	+0.23
DAPT RoBERTa + R-Drop	是	是	80.01±0.62	80.60	+1.37	+1.45

DAPT 是主要增益来源：仅 DAPT 已把同标签集成从 79.15% 提高到 80.45%；仅 R-Drop 为 79.38%。二者结合后，五个单成员均值达到 $80.01 \pm 0.62\%$ ，相对固定 split 基线均值提高 +2.40 pp；同标签五模型集成为 80.60%，相对本地基线集成提高 +1.45 pp，相对论文报告点高 +1.37 pp。

4.2 逐初始化配对与不确定性

表 7 同一标签集、同一初始化种子的逐成员配对结果。五个差值全部为正。

初始化种子	基线 Macro-F1	DAPT+R-Drop Macro-F1	配对差值 (pp)
100	78.76	80.09	+1.33
101	75.47	80.37	+4.90
102	76.77	78.92	+2.15
103	78.43	80.30	+1.87
104	78.61	80.38	+1.77
均值 ±SD	77.61±1.44	80.01±0.62	+2.40

五个配对差值的均值为 +2.40 pp，配对 t 区间为 $[+0.63, +4.17]$ pp ($p = 0.0197$)。但 $n = 5$ 很小，精确双侧符号检验为 $p = 0.0625$ ，因此不把单一参数检验写成最终显著性结论。对五成员集成做 5,000 次重采样时，结果如下。

表 8 DAPT+R-Drop 同标签集成相对固定 split 基线集成的 paired bootstrap。

重采样单位	集成差值 (pp)	95% CI (pp)	$P(\Delta \leq 0)$
逐行	+1.45	[+0.85, +2.06]	0.0000
按直播间聚类 (12 组)	+1.45	[+0.77, +2.45]	0.0000

逐行区间为 $[+0.85, +2.06]$ pp，按 12 个直播间聚类后的区间为 $[+0.77, +2.45]$ pp，均未跨 0。这支持“新方法相对本地同协议基线有增益”；相对论文的差值仍只能描述性解释，因为论文未公开逐样本预测且未说明 F1 averaging。

成立范围

严格实验保持人工标签不变，但不是同计算/同数据预算：DAPT 额外读取 21,159 条无标签训练文本，五模型集成约需单模型 5 倍计算。发布划分中还有 1,310 条测试弹幕与训练分区存在完全相同的表面文本 (14.44%)；DAPT 没有读取测试文件，但该重复限制了“全新文本泛化”的强主张。此外，本项目此前已观察过公开测试集，因此本轮属于锁定协议后的探索性验证，不是形式上的盲测。

5 必须使用大模型的完整改进：Qwen 选择性证据复核

本轮真正加入大模型后的主结果

冻结的 Qwen3:8B Q4_K_M 不做全量直接分类，也不把长解释强行拼入 RoBERTa。它只复核 DAPT+R-Drop 集成拿不准的样本，并且只有“多视角共识、置信度达标、证据可在当前弹幕逐字找到”同时成立时才允许改写预测。完整测试集 Macro-F1 从 80.60% 提高到 80.94%，大模型带来的本地增量为 +0.34 pp。

5.1 相对原论文的方法改进

原论文 §5.2–5.3/ Fig. 5 的做法是：对每条弹幕读取前 20 条上下文，由 LLM 生成语义解释 E_t ，再把原文与解释拼接后送入 soft prompt 模型。原论文 Table 6 的 Qwen3:8B 则使用 1,000 个样本做 PEFT，并作为独立分类器。本地实验把大模型改成第三种角色：**检索约束、可拒答的选择性复核器**。

表 9 原论文大模型用法与本地完整方法的逐项对应。最后一行明确了本实验没有覆盖的论文组件。

对照维度	原论文 §5.2–5.3 / Fig. 5	本地选择性 Qwen	改进及边界
大模型角色	为每条弹幕生成语义解释	只复核学生模型低置信样本	从全量特征生成改为选择性决策复核
时序上下文	前 20 条弹幕用于解释生成	前 20 条只用于指代和语境消歧	最终证据仍必须来自当前弹幕
领域锚点	解释文本与动态 verbalizer	每类检索 3 条严格训练样本	不增加人工标签，但会重复使用已有标签
输出约束	自由生成解释文本	JSON 标签、置信度、原文证据、弃权标志	无合法证据即不能覆盖学生
稳健性机制	解释生成一次后直接拼接	显式行为、潜在意图、负向过滤三视角投票	前两票高置信一致时早停，否则调用第三票
融合方式	原文与解释拼接后送入 soft prompt	仅在门控触发且至少两票一致时改写预测	无共识时自动保留学生答案
大模型覆盖	原则上覆盖全部弹幕	只覆盖完整测试集的 17.58%	节省调用，但不是无成本
流式词表更新	动态 verbalizer 与半衰期更新	当前没有在线词表更新	不能宣称解决原论文的概念漂移问题

设五模型平均的正类概率为 $\bar{p}_t$ ，验证集锁定的门控半宽为 $\delta = 0.32$ ，则

$$G_t = \mathbb{I}(|\bar{p}_t - 0.5| \leq \delta), \quad \hat{y}_t = \begin{cases} \hat{y}_t^{\text{Qwen}}, & G_t = 1 \wedge A_t = 1, \\ \mathbb{I}(\bar{p}_t \geq 0.5), & \text{otherwise.} \end{cases} \tag{1}$$

其中 $A_t = 1$ 要求至少两种视角给出同一标签、支持票平均置信度不低于 80，且证据是当前弹幕的原文子串。每次调用提供前 20 条无标签上下文和每类 3 条严格训练示例；生成配置固定为 temperature 0、think=false、num_predict=64、num_ctx=2048。

5.2 验证集选门与测试标签隔离

门控半宽只在锁定的 140 条验证集上选择。无门控时验证 Macro-F1 为 73.51%，候选区间在相同验证集上扫描后选择 $\delta = 0.32$ ，对应 79.11%；这两个数只用于选规则，不是最终性能结论。选定后冻结提示词、模型 digest、解析器、检索数、三视角 reducer 和输入签名，再运行完整 9,069 条测试集；测试标签只在预测与选择文件落盘之后加载。协议哈希前缀为 050c441f0ffb，模型 digest 前缀为 e4b5fd7f8af0。

验证集也可能过拟合

验证集只有 140 条，且 δ 来自多候选扫描，因此 79.11% 不能与论文或测试结果直接比较。本报告只把冻结后完整测试集的 80.94% 当作结果，并单独报告配对 bootstrap。

5.3 完整测试集结果与原论文对比

表 10 大模型相关主结果。论文两行取自原文 Table 5 (p.14) 和 Table 6 (p.16)；本地两行使用同一固定人工标签集和同一测试集。本地 Prec./Rec./F1 为宏平均，论文 averaging 未说明。

来源	方法	人工监督	大模型角色	Acc.	Prec.	Rec.	F1
论文 Table 5	SPT-RII 70-shot	70-shot; 等大验证集	逐条生成解释并输入提示模型	80.62 ± 0.37	79.96 ± 0.32	80.30 ± 0.23	79.23 ± 0.31
论文 Table 6	Qwen3:8B PEFT	1,000 样本	微调后的独立分类器	76.11	75.04	75.54	75.24
本地 严格实验	DAPT+R-Drop 集成	70/类训练与验证	推理期不用大模型	81.55	80.73	80.48	80.60
本地 完整方法	DAPT+R-Drop + 选择性 Qwen	同一人工标签集	只复核低置信样本	82.10	81.61	80.49	80.94

选择性 Qwen 的 Accuracy、Macro-Precision、Macro-Recall 和 Macro-F1 分别为 82.10%、81.61%、80.49% 和 80.94%。与同一逐行预测上的无大模型学生相比，Macro-F1 提高 +0.34 pp；与论文 Table 5 的 SPT-RII 70-shot 报告点相比，描述性差值为 +1.71 pp。

相对论文 Table 6 的 Qwen3:8B PEFT 行，数值差为 +5.70 pp，但这不能解释为“本地 Qwen 本身高了 5.70 个百分点”：Table 6 是 1,000 样本 PEFT 的独立分类器，而本地结果是 DAPT+R-Drop 学生与冻结 Qwen 复核器组成的系统，标签预算、模型角色和指标定义均不同。




图 3 选择性 Qwen 完整结果。a, 论文 Table 5/Table 6 与本地学生/完整方法的性能点; b, 只有低置信样本进入 Qwen; c, 改对、改错和净增正确项; d, 相对本地学生的逐行与直播间聚类 paired bootstrap 区间。两条区间均跨 0。

5.4 Qwen 到底改对了多少

表 11 选择性复核的路由与错误账本。百分比均以完整 9,069 条测试集为分母, 除最后一列外。

路由阶段或结果	条数	占测试集	占改写预测
完整测试集	9,069	100.00%	—
进入 Qwen 的低置信样本	1,594	17.58%	—
Qwen 形成有效共识	1,567	17.28%	—
最终改变小模型预测	648	7.15%	100.00%
其中: 纠正原错误	349	3.85%	53.86%
其中: 破坏原正确项	299	3.30%	46.14%
净增加正确预测	+50	+0.55%	—

完整测试集中有 1,594 条进入 Qwen, 1,567 条形成有效共识, 最终有 648 条改变学生预测。Qwen 纠正 349 个基线错误, 同时破坏 299 个原本正确的样本, 净增加 +50 个正确预测。这个账本说明大模型确实提供了互补判断, 但其意见并非天然可靠; 证据校验、共识与保留学生答案都是必要的保险。

5.5 统计边界：有正向点估计，尚无稳健显著性

表 12 选择性 Qwen 相对本地 DAPT+R-Drop 集成的 5,000 次 paired bootstrap。

重采样单位	点差 (pp)	95% CI (pp)	$P(\Delta \leq 0)$
逐行	+0.34	$[-0.26, +0.92]$	0.135
按 live_id 聚类 (12 组)	+0.34	$[-0.37, +1.54]$	0.251

两条 95% 区间都跨 0，所以本轮可以说“Qwen 将点估计从 80.60% 进一步推到 80.94%”，但不能说“Qwen 已显著提高性能”。跨论文的 +1.71 pp 更不能做显著性检验，因为原论文没有公开逐行预测，且 F1 averaging 未说明。

5.6 RTX 4060 可运行性与额外成本

Qwen 只覆盖 17.58% 的测试样本，但每个候选需要 2–3 个视角。缓存中成功记录的推理时间累计约 98.3 min；正式重建阶段利用缓存，只重试 68 条无效记录，用时 240.6 s。该计时不等同于论文 Table 9 的“单条解释生成时间”，也不包含学生模型训练。正式重建的显存监控没有捕获有效峰值；同一量化模型在此前直接调用中测得约 6.40 GiB，说明 8 GB RTX 4060 可以运行，但全量实验仍需约 1.5–2 h 的大模型推理时间。

当前结论的准确写法

“在固定同一份 70-shot/类人工标签和完整 RecDY 测试集上，DAPT+R-Drop 同标签集成 为 80.60% Macro-F1；加入证据约束的 Qwen3:8B 选择性复核后，点估计提高到 80.94%。该完整系统描述性高于论文 Table 5 的 79.23%，但 Qwen 的额外 +0.34 pp 增量区间跨 0， 仍需未触碰测试集确认。”

6 内部提升：对应 §5.3、§6.6 Fig.6，但协议不同

可比性等级：C

以下实验使用 400 条固定本地测试子集，训练规模为 400 或 1,000。它们用于判断本地改进是否有效，不能把绝对 F1 直接减去论文 Table 5。

6.1 字符 TF-IDF：解释分通道与 OOF 晚期融合

表 13 TF-IDF 改进实验。置信区间为测试样本配对 bootstrap；跨 0 表示证据尚不足。

训练量	方法	Macro-F1	相对基线	不确定性/备注
400	内容基线	78.88%	基准	–
400	旧 Qwen 解释直接拼接	80.75%	+1.87 pp	95% CI [−2.80, +6.69]
400	结构化解释直接拼接	80.84%	+1.96 pp	相对旧提示仅 +0.09 pp
400	旧解释 + OOF 晚期融合	82.39%	+3.51 pp	95% CI [−0.32, +7.35]
400	结构化解释 + OOF 晚期融合	80.03%	+1.14 pp	95% CI [−1.00, +3.41]
1000	内容基线	82.29%	基准	–
1000	结构化解释直接拼接	82.94%	+0.65 pp	–
1000	结构化解释 + OOF 晚期融合	83.82%	+1.53 pp	95% CI [−1.28, +4.34]

数据量和融合策略有价值，但“改成结构化提示”本身没有稳定胜过旧提示。400 条时旧解释 late fusion 最强；1,000 条时结构化 late fusion 相对内容基线提高 1.53 pp。

6.2 RoBERTa: compact explanation 与验证集融合

表 14 RoBERTa 三种子结果。1000 条 compact late fusion 的逐种子提升为 +0.154/ + 0.746/ + 0.401 pp。

训练量	输入/融合	Macro-F1 均值 ±SD	相对内容基线	判断
400	内容基线	84.90 ± 1.52%	基准	–
400	旧 Qwen 直接拼接	82.57 ± 0.67%	−2.34 pp	退化
400	结构化解释直接拼接	82.44 ± 1.66%	−2.46 pp	退化
400	compact 直接拼接	84.30 ± 1.75%	−0.60 pp	基本追回
400	compact late fusion	84.88 ± 0.61%	−0.03 pp	种子方向不一致
1000	内容基线	87.19 ± 0.53%	基准	–
1000	结构化解释直接拼接	86.73 ± 1.12%	−0.46 pp	仍退化
1000	compact 直接拼接	87.21 ± 0.51%	+0.02 pp	接近持平
1000	compact late fusion	87.63 ± 0.29%	+0.43 pp	三个种子均为正

RoBERTa 对噪声解释敏感。长解释直接拼接会破坏内容信号；缩短解释并改为 late fusion 后，1,000 条训练下得到小幅且三个种子同方向的提升，但 $n = 3$ 仍不足以声称统计显著。




图 4 内部改进总览：TF-IDF、RoBERTa 与额外计算开销。误差线定义见原实验记录。

6.3 与原论文 Fig.6 的对应方式

表 15 原论文 Fig.6 与本地内部消融的概念映射。绝对值不作横向胜负比较。

实验	F1/Macro-F1	组件变化	比较边界
原论文完整 SPT-R11	78.3%	–	同一 SPT-R11 框架
原论文 –explanations	74.0%	–4.3 pp	证明解释模块重要
原论文 –update	75.5%	–2.8 pp	证明动态更新重要
本地 TF-IDF 1000 late fusion	83.82%	+1.53 ppvs 本地内容	不同模型/测试子集
本地 RoBERTa 1000 compact late fusion	87.63 ± 0.29%	+0.43 ppvs 本地内容	不同模型/测试子集

7 前期小样本门控探索：对应 §6.7 / Table 6

本节保留在正式严格实验之前完成的 400 条子集探索，用于说明方案是如何形成的；它不是当前主结果。原论文 Table 6 比较了 10-shot LLM、1,000 样本 PEFT 与 SPT-RII。该前期实验没有让 Qwen 全量替代分类器，而只处理 TF-IDF 置信度落在 [0.28,0.72] 的样本；阈值在 200 条验证集上选择，测试子集评估一次。正式 9,069 条测试结果见图 3 与表 10。

表 16 不确定性门控结果。提升区间跨 0，因此属于探索性证据。

方法	Macro-F1	测试数	Qwen 覆盖	相对基线
TF-IDF 基线	82.29%	400	0%	基准
Qwen 直接分类	74.70%	400	100%	单独使用更差
不确定性门控	83.71%	400	38.5%	+1.42 pp; 95% CI [-2.61, +5.37]

154 条被路由样本上，Qwen 纠正 33 个基线错误，同时破坏 28 个原本正确样本，净增 5 条正确预测。混淆矩阵从 [[120,37],[30,213]] 变为 [[125,32],[30,213]]，主要减少 5 个负类被误报为正类的错误。




图 5 不确定性门控：验证集选阈值，固定测试集一次评估。

为什么不能与 Table 6 直接相减

论文 Table 6 的大模型行是另一套 few-shot/PEFT 条件；本节门控只在 400 条子集上评估，还把 TF-IDF 与 Qwen 组合。83.71% 不能写成“比论文 SPT-RII 78.32% 高 5.39 pp”，也不能替代当前严格同标签预算的 80.94% 主结果。

8 效率：对应 §6.10 / Table 9 / p.17

表 17 原论文 Table 9 与本地生成开销。硬件、量化、计时范围和任务均不同。


来源	模型	报告 F1	时间	硬件	任务含义
论文	Llama3.1-8B	75.79%	257 ms/条	RTX 4090	作为 SPT-RII 解释器
论文	Qwen2.5-7B	76.74%	283 ms/条	RTX 4090	作为 SPT-RII 解释器
论文	Deepseek-V3	78.32%	985 ms/条	未单列	远程/大模型设置
论文	ChatGPT-3.5	79.09%	1072 ms/条	服务端	远程 API
论文	ChatGPT-4o	78.60%	1062 ms/条	服务端	远程 API
本地	Qwen3-8B Q4	非同一 F1	562 ms/条	RTX 4060 8 GB	800 条墙钟 450.2 s; 峰值 6.40 GiB
本地严格	Qwen3:8B Q4_K_M	80.94%	累计约 98.3 min	RTX 4060 8 GB	路由 1,594 条; 每条 2-3 视角

原论文 Table 9 测的是“更换 SPT-RII 解释生成模型后的整体 F1 和单条时间”；本地 0.562 s/条只统计早期 Qwen3-8B Q4 的解释生成，严格选择性复核的 98.3 min 是缓存中成功调用的累计推理时间。任务、提示长度、调用次数、量化和硬件都不同，因此这里只能证明 RTX 4060 可以跑通并量化本地成本，不能得出速度优越性结论。

9 如何通俗解释这次提升

30 秒讲法

可以把系统理解为“学生先答，老师只检查难题”。RoBERTa 先阅读训练分区无标签弹幕，熟悉直播语言，再用 R-Drop 稳住少样本学习；五模型学生集成为 80.60%。只有学生拿不准的 17.58% 样本才交给 Qwen，而且 Qwen 必须引用弹幕原话、至少两种视角一致，才有资格改答案。最终 Macro-F1 为 80.94%，比学生高 +0.34 pp，比论文 Table 5 的 79.23% 描述性高 +1.71 pp；但大模型这一小段增量的区间跨 0，所以应说“点估计更高”，不能说“已经显著提升”。



口径：固定同一 70/类训练集与 70/类验证集；5 个模型只改变初始化/Dropout。DAPT 额外使用训练分区 21,159 条无标签弹幕；集成不增加人工标签，但约需 5 倍模型计算。
论文仅写 F1，未说明 averaging；本地使用 Macro-F1，因此跨论文差值为描述性比较。

图 6 面向汇报的严格同预算对照图。a，论文报告点、本地固定 split 初始化均值和同标签集成点；b，DAPT/R-Drop 的 2×2 消融，主要增益来自 DAPT；c，五个同种子配对差值全部为正，并给出逐行与直播间聚类 bootstrap 区间。

9.1 按两张图讲四句话

1. 先讲标签预算。看图 6a：五个成员使用相同的 140 条训练标签和 140 条验证标签；DAPT+R-Drop 单成员均值与同标签集成均越过论文 79.23% 报告点。
2. 再讲学生为什么变强。看图 6b：只加 R-Drop 的集成提高 0.23 pp，只做 DAPT 已提高 1.30 pp，两者结合提高 +1.45 pp。核心是先用无标签数据熟悉直播语言，再用一致性训练降低波动。
3. 然后讲大模型怎么用。看图 3b–c：Qwen 不做所有题，只复核 1,594 条低置信样本；它改对 349 条、改错 299 条，净增加 +50 条正确预测，最终把 80.60% 推到 80.94%。
4. 最后讲证据边界。图 6c 表明 DAPT+R-Drop 相对基础学生的区间未跨 0；但图 3d 中 Qwen 额外增量的逐行区间 $[-0.26, +0.92]$ pp、聚类区间 $[-0.37, +1.54]$ pp 都跨 0。前者证据较稳，后者目前只是正向点估计。

最容易讲错的地方

不建议说：“我们完全复现并在所有条件下显著超过了 SPT-R11。”

建议说：“在固定同一份 70-shot/类人工标签后，DAPT+R-Drop 同标签集成为 80.60%；再让 Qwen 只复核低置信样本，完整方法达到 80.94%。这比论文 Table 5 的 79.23% 描述性高 +1.71 个百分点。大模型确实让点估计再提高 +0.34 个百分点，但其置信区间跨 0，因此还不能说额外提升已经显著。”

9.2 老师追问时的简短回答

- 问：为什么不能直接拿 83.82% 或 87.63% 与论文的 79.23% 比？
- 答：因为它们来自 1,000 条训练、400 条测试的内部实验，测试样本和训练预算都不同。只有完整 9,069 条测试集上的 50/60/70-shot 实验最接近论文 Table 5。
- 问：现在能不能说对论文有进步？
- 答：可以说“在同人工标签预算、完整 RecDY 测试集上，包含 Qwen 的完整系统达到 80.94%，描述性超过论文报告点 79.23%”。不能说完整复现 SPT-R11，也不能说同计算/同总数据预算。
- 问：大模型是不是被放弃了？
- 答：没有。Qwen 从“每条都写解释”改成了“只审难题的复核器”。它实际处理 1,594 条样本，必须给出原文证据并形成多视角共识，最终净增加 +50 条正确预测。
- 问：这些提升算不算已经证明有效？
- 答：要分两层。DAPT+R-Drop 相对本地基础学生的逐行和直播间聚类区间都未跨 0；Qwen 在其上额外增加的 +0.34 pp 区间跨 0，因此只能称正向点估计。公开测试集此前还被观

察过，仍需未触碰数据确认。

问：到底是 DAPT 还是 R-Drop 起作用？

答：主要是 DAPT。集成层面只加 R-Drop 为 +0.23 pp，只加 DAPT 为 +1.30 pp，二者结合为 +1.45 pp；R-Drop 更明显的作用是把单成员 SD 从 1.44 降到 0.62 个百分点。

问：4060 能承担吗？

答：可以。DAPT 用时 214.1 s、峰值 2.42 GiB；监督 R-Drop 单成员峰值约 2.16 GiB。Qwen 成功调用的累计推理时间约 98.3 min，同量化模型此前直接调用峰值约 6.40 GiB。可以单卡顺序完成，但不是实时零成本方案。

10 可信度、限制与下一步

10.1 目前可以成立的结论

- 严格 70-shot 实验已固定同一组训练/验证行、五个初始化、阈值 0.5 和完整 9,069 条测试集；四个预注册消融条件均已报告，没有只挑最高条件。
- DAPT+R-Drop 单成员均值为 $80.01 \pm 0.62\%$ ，同标签集成为 80.60%，相对本地固定 split 基线的配对 bootstrap 区间未跨 0。
- 冻结 Qwen3:8B 以检索增强、证据约束的选择性复核器参与完整测试；系统达到 80.94% Macro-F1，相对论文 Table 5 描述性高 +1.71 pp。
- 大模型相对本地学生的额外点差为 +0.34 pp；逐行和直播间聚类区间都跨 0，因此只称“进一步提高点估计”，不称统计显著。
- 2×2 消融确认主要增益来自 DAPT；R-Drop 单独收益小，但与 DAPT 结合后进一步提高单成员均值并降低固定 split 下的初始化波动。
- 1,000 条训练时，TF-IDF late fusion 提高 1.53 pp；RoBERTa compact late fusion 提高 0.43 pp，三个种子方向一致。
- 路由账本显示 Qwen 改对 349 条、改错 299 条、净增 +50 条；选择性使用比前期全量直接分类更合理，但仍有明确副作用。

10.2 不能忽略的限制

表 18 结果解释所需的边界条件。

风险	事实	文档处理
指标定义	论文未明确 F1 averaging；本地用 Macro-F1	所有跨论文差值标为近似口径
方法完整性	未实现 soft prompt、BiLSTM、动态 verbalizer	称为低成本替代，不称完整复现
无标签数据预算	DAPT 读取训练分区 21,159 条无标签弹幕	称“同人工标签预算”，不称同总数据预算
集成计算预算	五个成员共享标签，但约需单模型 5 倍微调/推理	同时报告单成员均值与集成单点
大模型额外计算	1,594 条候选各需 2–3 个视角；累计记录约 98.3 min	报告覆盖率、调用成本与缓存修复，不称免费提升
门控选择	140 条验证集扫描不确定性区间，可能选择性过拟合	测试只在锁定后评估；仍需新验证集复核
Qwen 增量功效	+0.34 pp；逐行 CI [−0.26, +0.92]，聚类 CI [−0.37, +1.54]	只称正向点估计，不称显著提升
测试历史	公开 RecDY 测试集此前已被本项目观察	定位为锁定协议后的探索性验证，不称正式盲测
重复表面文本	1,310 条测试弹幕与训练分区文本完全相同	限制“全新文本泛化”主张
同直播间相关性	12 个 live_id 同时出现在训练/测试	补充直播间聚类 bootstrap；仍需跨直播间留出
统计功效	固定 split 只有 5 个初始化；符号检验 $p = 0.0625$	不把跨论文差值写成正式显著性结论

10.3 下一轮优先实验

1. 将已锁定的 DAPT+R-Drop + Qwen 完整规则原样运行在未触碰的平台或按 live_id 完整留出的测试集，确认 +0.34 pp 是否可重复。
2. 对 Qwen 组件做预注册消融：去检索示例、去原文证据检查、固定两票、固定三票、禁止上下文；验证收益究竟来自哪一项约束。
3. 把严格协议扩展到 50/60-shot，验证相对论文 Table 5 的增益是否贯穿不同标注规模，而不是只出现在 70-shot。
4. 比较单模型 checkpoint averaging、五模型集成与 Qwen 路由，绘制 Macro-F1–耗时曲线，争取把约 5 倍学生计算和 1.5–2 h 大模型推理压缩到可部署水平。

最终判断

本轮已经形成一个实际使用大模型的完整系统：在固定同一份 70-shot/类人工标签后，DAPT+R-Drop 同标签集成为 80.60%，证据约束的 Qwen 选择性复核把点估计进一步提高到 80.94%。该结果相对论文 Table 5 的 79.23% 为描述性 +1.71 pp，但 Qwen 自身的 +0.34 pp 增量区间跨 0。最稳妥的表述是“在 RTX 4060 上，同人工标签预算的本地完整方法获得了高于论文报告点的受控结果，大模型带来额外正向点估计”；不能写成完整复现、同计算预算或显著击败 SPT-RII。

11 证据文件索引

以下路径对应本文全部数字和原文位置。source_map.json 提供 S/T 锚点，CSV/JSON 文件提供本地逐种子、融合和门控证据。

原论文 PDF	E:\zotero\storage\7DATFQRR\Zhu 等-2026-AnalyzingbulletchatsforrecommendationintentidentificationDatasetandmethod.pdf
原文位置映射	E:\Lab\experiment\paper_reader\source_map.json
Table 5 原图	E:\Lab\experiment\paper_reader\assets\table5_recdy.png
Table 5 对比目录	E:\Lab\experiment\results\paper_comparison
历史内部实验目录	E:\Lab\experiment\results\improvement
严格协议清单	E:\Lab\experiment\config\same_budget_protocol_v1.json
DAPT 无标签适配	E:\Lab\experiment\results\same_budget\dapt_result.json
严格四条件汇总	E:\Lab\experiment\results\same_budget\strict70_analysis.json
严格逐成员指标	E:\Lab\experiment\results\same_budget\strict70_member_metrics.csv
严格 bootstrap	E:\Lab\experiment\results\same_budget\strict70_bootstrap.csv
严格对照图源数据	E:\Lab\experiment\figures\source_data_fig8.csv
Qwen 验证锁定	E:\Lab\experiment\results\same_budget\strict70_qwen_gate_selection.json
Qwen 正式结果	E:\Lab\experiment\results\same_budget\strict70_qwen_gate_result.json
Qwen 统计分析	E:\Lab\experiment\results\same_budget\strict70_qwen_gate_analysis.json
Qwen 逐行预测	E:\Lab\experiment\results\same_budget\strict70_qwen_gate_predictions.csv
Qwen 改写样本	E:\Lab\experiment\results\same_budget\strict70_qwen_gate_changed_cases.csv
Qwen 对照图源数据	E:\Lab\experiment\figures\source_data_fig9.csv