

提升数据与原论文 逐项对比

RTX 4060 本地实验：性能提升、可比性边界与原文位置索引

对照论文	Zhu et al., <i>Analyzing bullet chats for recommendation intent identification: Dataset and method</i> , <i>Artificial Intelligence</i> 355 (2026) 104528
核心数据集	RecDY；论文固定测试集，本地协议对齐测试 $n = 9,069$
本地环境	NVIDIA GeForce RTX 4060 Laptop GPU，8 GB 显存
主交付格式	XeLaTeX 源文件与编译 PDF
报告日期	2026 年 7 月 18 日

一句话结论

本地低成本方案在内部实验上取得可重复的局部提升。与论文 Table 5 最接近的 70-shot/类独立运行结果为 $78.00 \pm 0.14\%$ ，比论文 $79.23 \pm 0.31\%$ 低 1.23 pp；三模型工程集成达到 81.65%，描述性高 2.42 pp，但三个成员重新抽样，训练并集为 420 条，不能表述为同预算单模型超过 SPT-RII。

目录

1	结论先行	1
2	原论文位置索引与本地对应	2
3	主对比：原论文 §6.5 / Table 5 / p.14	3
3.1	F1 主结果	3
3.2	Table 5 四指标复核	5
4	内部提升：对应 §5.3、§6.6 Fig.6，但协议不同	6
4.1	字符 TF-IDF：解释分通道与 OOF 晚期融合	6
4.2	RoBERTa：compact explanation 与验证集融合	6
4.3	与原论文 Fig.6 的对应方式	7
5	不确定性门控：对应 §6.7 / Table 6，仅概念对照	8
6	效率：对应 §6.10 / Table 9 / p.17	9
7	如何通俗解释这次提升	10
7.1	按图讲三句话	11
7.2	老师追问时的简短回答	11
8	可信度、限制与下一步	12
8.1	目前可以成立的结论	12
8.2	不能忽略的限制	12
8.3	下一轮优先实验	12
9	证据文件索引	13

1 结论先行

本项目没有完整复现 SPT-RII 的 soft prompt、BiLSTM prompt interaction、动态 verbalizer 和词性/语义锚更新，而是在 RTX 4060 8 GB 条件下建立了一条低成本替代路线：扩大训练规模、压缩解释、验证集/OOF 融合、三种子概率集成，以及只在低置信样本上调用 Qwen 的不确定性门控。

表 1 结果层级与主要判断。只有第一行属于最接近原论文协议的独立运行对照。

比较层级	实验	本地结果	变化	判断
协议对齐	70-shot 独立运行	78.00 ± 0.14%	−1.23 pp	最接近论文 Table 5
工程集成	70-shot 三种子概率集成	81.65%	+2.42 pp	累计标注覆盖更大
内部改进	TF-IDF, 1,000 训练	82.29 → 83.82%	+1.53 pp	CI 跨 0
内部改进	RoBERTa, 1,000 训练	87.19 ± 0.53 → 87.63 ± 0.29%	+0.43 pp	三个种子均为正
探索性改进	不确定性门控	82.29 → 83.71%	+1.42 pp	95% CI [−2.61, +5.37]

指标口径

原论文只写 F1/Prec./Rec.，没有说明 macro、micro 或 weighted averaging；本地使用 scikit-learn Macro-F1/Macro-Precision/Macro-Recall。因此跨论文差值属于近似口径对照，不声称指标定义完全等价。论文正文也未明说 50/60/70-shot 是“每类”还是“总数”；本地依据公开实现按每类 shot 执行。

改进主要来自四点：训练规模从 400 扩到 1,000；内容与解释分通道建模；使用 OOF/验证集选择融合权重和阈值；仅让 Qwen 处理低置信样本。三种子概率集成降低了抽样波动，但由于各成员重新抽样，它同时扩大了累计标注覆盖，必须与独立运行均值分开报告。

2 原论文位置索引与本地对应

PDF 页码与论文印刷页码一致。表 2 按“原论文位置 → 原文作用 → 本地对应 → 可比性”组织，读者可直接回到原文核验。

表 2 原论文与本地实验的位置级映射。S/T 编号来自 paper_reader/source_map.json。

主题	原论文精确位置	原文内容	本地对应与关系
问题动机	§5.1, p.8, S0064	短弹幕依赖上下文；流式语义锚会被稀释	上下文重构与解释增强； 概念对应
解释生成	§5.2–5.3, pp.9–10, Fig.5, S0066–S0073	LLM 在前 20 条滑窗内做语境语义重构	Qwen 背景与 compact explanation； 概念对应
提示学习	§5.4, p.10, S0073/S0077	Soft prompt + BiLSTM 交互	用 RoBERTa/TF-IDF 替代； 未复现
动态标签词	§5.5–5.6, pp.10–12, S0080–S0101	POS 候选、语义距离、half-life=10、Top- <i>k</i> 更新	验证集融合/门控替代； 未复现
数据协议	§6.1, p.12, S0109	各平台 70% train / 30% test；测试集只作最终评估	RecDY 固定 test <i>n</i> = 9,069； 协议对齐
训练设置	§6.3–6.4, p.13, S0113	50/60/70-shot；验证集等大；3 次重复；RTX 4090	每类 shot；种子 100/101/102；RTX 4060；近似对齐
主结果	§6.5, Table 5, p.14, T001	RecDY SPT-RII F1 为 77.84/78.92/79.23	独立均值与工程集成； 协议对齐
消融	§6.6, Fig.6, p.15, S0116/S0117	去解释 −4.3 pp；去更新 −2.8 pp	解释通道与 late fusion； 概念对应
大模型	§6.7, Table 6, p.16, S0117/S0118	LLM/PEFT 与 SPT-RII 对照	Qwen 直接分类/不确定性门控；协议不同
效率	§6.10, Table 9, p.17, S0186/S0210	更换解释模型后的 F1 与时间	Qwen3-8B Q4 生成时间/显存； 描述性对照
参数敏感性	§6.12, Fig.9, pp.19–20, S0264/S0266	窗口 0 → 20 提升，过大引入过噪	压缩上下文、验证集融合；设计依据
错误分析	§6.13, pp.20–21, S0266	隐式语义、上下文不足等错误	门控净纠正 5 条； 概念对应

未覆盖内容

本地没有复现 Table 7 的 BTD 外部数据、Table 8 的跨平台迁移、Table 10 的蒸馏、Table 11/Fig.8 的模板实验，以及 Fig.9 的完整参数扫描。它们只列入索引，不参与提升结论。

3 主对比：原论文 §6.5 / Table 5 / p.14

可比性等级：A-

同为 RecDY 固定测试集 $n = 9,069$ ，训练/验证按 50、60、70-shot 抽样，并报告 3 次独立运行。差异是模型结构、硬件和指标定义不完全相同；因此称“协议对齐的描述性比较”，不称 SPT-RII 完整复现。

Y. Zhu, Q. Han, Y. Yuan et al.

Artificial Intelligence 355 (2026) 104528

Table 5
Experimental results across four platforms and all baselines under varying data conditions. All the results are presented as average value $\pm$ SD (%). Bold indicates the best result, and underline indicates the second-best result.

Platform	Method	200/200/50/0/50				400/400/60/0/60				800/800/70/0/70			
		Acc.	Prec.	Rec.	F1.	Acc.	Prec.	Rec.	F1.	Acc.	Prec.	Rec.	F1.
RecDY	Text-CNN	65.14±0.48	63.67±0.08	63.73±0.47	63.61±0.26	68.18±0.59	68.05±0.77	68.90±0.83	67.77±0.66	70.89±0.13	70.99±0.18	71.98±0.19	70.58±0.13
	ADB	57.28±2.08	42.01±0.80	38.21±1.71	39.75±1.16	57.55±1.40	42.73±1.02	38.91±1.38	40.17±0.97	59.05±0.62	44.94±0.28	40.25±0.78	41.68±0.27
	SimSTC	63.13±0.05	63.52±3.22	56.72±1.38	53.82±3.00	64.39±0.47	67.08±1.91	57.36±1.06	53.88±2.38	65.32±0.05	66.15±0.24	59.17±0.11	57.31±0.22
	SHINE	68.15±0.96	67.39±1.79	63.24±0.41	63.24±0.27	69.63±0.62	70.25±0.81	64.10±0.74	63.97±0.83	70.25±0.80	72.10±1.90	64.34±0.57	64.09±0.58
	NC-HGAT	67.21±0.48	67.01±0.42	67.81±0.44	66.76±0.46	69.70±0.10	69.75±0.12	70.68±0.12	69.36±0.09	73.19±0.11	73.33±0.09	74.43±0.09	72.92±0.10
	GIFT	66.24±0.24	64.01±0.24	63.90±0.50	63.93±0.39	67.18±0.42	64.92±0.27	64.68±0.09	64.76±0.10	68.10±0.34	65.73±0.40	65.02±0.47	65.26±0.45
	BERT	57.73±1.31	52.48±1.12	51.70±1.12	49.16±3.67	70.53±1.04	69.18±0.94	69.18±1.29	69.12±1.12	71.61±2.09	71.90±1.02	72.56±0.88	71.17±1.69
	IntentBERT	63.82±0.15	65.85±0.17	63.82±0.15	62.51±0.16	62.18±0.15	63.83±0.18	62.18±0.15	60.86±0.16	62.00±0.15	63.30±0.17	62.00±0.15	60.73±0.16
	IntentBERT-MLM	63.52±0.14	65.41±0.16	63.52±0.14	62.29±0.15	65.86±0.15	67.36±0.16	65.86±0.15	64.85±0.15	65.02±0.16	66.73±0.18	65.02±0.16	63.77±0.17
	KPT	74.53±3.06	74.15±1.69	74.59±1.28	73.82±2.41	76.38±3.17	75.76±2.89	76.88±2.89	75.86±2.99	77.78±2.38	77.07±2.47	77.59±2.14	77.11±2.22
	KPT++	75.86±1.50	74.99±1.45	75.75±1.45	75.19±1.52	76.25±1.48	75.30±1.47	75.50±1.66	75.30±1.63	77.38±1.30	76.40±1.38	76.73±1.37	76.47±1.35
	P-tuning	76.66±2.30	75.70±2.56	75.53±3.17	75.49±2.81	78.25±1.77	77.72±1.66	78.10±1.53	77.82±1.76	79.94±1.72	79.09±1.77	79.47±1.93	79.18±1.72
	MSP	73.37±0.56	72.21±1.26	72.63±0.79	72.38±0.36	73.98±0.46	73.74±0.93	74.86±0.63	73.61±0.38	74.95±1.62	74.16±1.25	75.08±1.71	74.35±1.58
	LLaMA3	61.74±0.24	59.66±0.21	59.46±0.25	59.54±0.25	61.74±0.24	59.66±0.21	59.46±0.25	59.54±0.25	61.74±0.24	59.66±0.21	59.46±0.25	59.54±0.25
RecKS	Deepseek-V3	67.93±0.09	69.71±0.03	70.28±0.05	67.88±0.08	67.93±0.09	69.71±0.03	70.28±0.05	67.88±0.08	67.93±0.09	69.71±0.03	70.28±0.05	67.88±0.08
	ChatGPT-4o	72.06±0.26	71.71±0.23	72.71±0.24	71.62±0.25	72.06±0.26	71.71±0.23	72.71±0.24	71.62±0.25	72.06±0.26	71.71±0.23	72.71±0.24	71.62±0.25
	FaithfulRAG	66.16±0.13	66.14±0.05	66.91±0.08	65.76±0.16	66.16±0.13	66.14±0.05	66.91±0.08	65.76±0.16	66.16±0.13	66.14±0.05	66.91±0.08	65.76±0.16
	SPT-RII(ours)	78.41±0.39	77.63±0.31	78.96±0.20	77.84±0.32	79.50±0.75	78.65±0.49	79.48±0.39	78.92±0.56	80.62±0.37	79.96±0.32	80.30±0.23	79.23±0.31
	Text-CNN	70.48±0.93	71.49±1.15	72.62±1.17	70.25±1.02	74.62±0.84	74.07±0.33	75.36±0.29	74.01±0.64	78.68±0.45	77.88±0.47	79.18±0.54	78.01±0.42
	ADB	62.34±3.91	44.02±2.26	41.18±2.50	42.35±2.47	68.41±0.48	49.68±0.08	45.12±0.34	47.24±0.18	67.49±0.35	50.60±0.80	44.47±0.46	47.29±0.56
	SimSTC	66.78±0.34	52.65±0.73	51.64±0.50	50.59±0.64	70.44±0.23	58.46±0.53	53.88±0.15	52.51±0.20	72.24±0.19	63.29±0.61	54.74±0.50	52.98±0.89

图 1 原论文 Table 5 的标题、表头与 RecDY 区域，来源：原论文 p.14。

3.1 F1 主结果

表 3 Table 5 核心 F1 对照。独立运行均值是主结果；集成列均为单个工程点，没有 SD。

shot/类	论文 SPT-RII F1±SD	本地独立均值 Macro-F1±SD	独立 差值	内容集成 单点	集成 差值	内容 + 字符 集成单点	融合 差值
50	77.84 ± 0.32	75.52 ± 1.67	-2.32	77.29	-0.55	77.29	-0.55
60	78.92 ± 0.56	77.00 ± 0.89	-1.92	78.86	-0.06	78.86	-0.06
70	79.23 ± 0.31	78.00 ± 0.14	-1.23	81.65	+2.42	81.85	+2.62

保持每次独立运行的 70-shot/类预算时，本地内容模型为 $78.00 \pm 0.14\%$ ，仍比论文 $79.23 \pm 0.31\%$ 低 1.23 pp。三模型内容概率集成达到 81.65%，相对论文报告点高 2.42 pp；再加入字符 TF-IDF 后为 81.85%，额外仅 +0.20 pp。

表 4 工程集成的累计标注覆盖。70-shot 集成整体看到 420 条训练样本，约 210/类。

每成员 shot/类	每成员训练总数	三成员训练并集	训练 + 验证总并集	内容集成点
50	100	299	592	77.29%
60	120	360	713	78.86%
70	140	420	824	81.65%

表述红线

可以说“工程集成点在固定测试集上达到 81.65%，描述性高于论文 Table 5 的 79.23%”；
不可说“我们以同等 70-shot 预算复现并超过 SPT-R11”。

Paper-matched comparison on the fixed RecDY test set




图 2 固定 RecDY 测试集上的论文对齐比较。误差线为独立运行 SD；空心标记为单个集成点。

3.2 Table 5 四指标复核

表 5 原论文 Table 5 与本地结果的 Accuracy/Precision/Recall/F1 复核，单位为百分比。集成行是单点。

shot/类	方法	Accuracy	Precision	Recall	F1
50	论文 SPT-R11	78.41 ± 0.39	77.63 ± 0.31	78.96 ± 0.20	77.84 ± 0.32
50	本地独立均值	76.59 ± 2.37	76.11 ± 2.80	75.74 ± 1.03	75.52 ± 1.67
50	本地内容集成	78.21	77.17	77.44	77.29
60	论文 SPT-R11	79.50 ± 0.75	78.65 ± 0.49	79.48 ± 0.39	78.92 ± 0.56
60	本地独立均值	78.09 ± 0.42	77.21 ± 0.31	77.06 ± 1.44	77.00 ± 0.89
60	本地内容集成	79.94	79.06	78.69	78.86
70	论文 SPT-R11	80.62 ± 0.37	79.96 ± 0.32	80.30 ± 0.23	79.23 ± 0.31
70	本地独立均值	79.26 ± 0.52	78.63 ± 0.92	77.76 ± 0.58	78.00 ± 0.14
70	本地内容集成	82.70	82.13	81.29	81.65

指标与论文内部不一致

论文表头为 Prec./Rec./F1，但 §6.4 未说明 averaging；本地三项采用宏平均。另有一处论文内部不一致：Table 5 的 RecDY 50-shot SPT-R11 F1 为 77.84 ± 0.32%，Table 6 同一标签写 78.32%。本文始终使用 Table 5 作为主参照。

4 内部提升：对应 §5.3、§6.6 Fig.6，但协议不同

可比性等级：C

以下实验使用 400 条固定本地测试子集，训练规模为 400 或 1,000。它们用于判断本地改进是否有效，不能把绝对 F1 直接减去论文 Table 5。

4.1 字符 TF-IDF：解释分通道与 OOF 晚期融合

表 6 TF-IDF 改进实验。置信区间为测试样本配对 bootstrap；跨 0 表示证据尚不足。

训练量	方法	Macro-F1	相对基线	不确定性/备注
400	内容基线	78.88%	基准	–
400	旧 Qwen 解释直接拼接	80.75%	+1.87 pp	95% CI [−2.80, +6.69]
400	结构化解释直接拼接	80.84%	+1.96 pp	相对旧提示仅 +0.09 pp
400	旧解释 + OOF 晚期融合	82.39%	+3.51 pp	95% CI [−0.32, +7.35]
400	结构化解释 + OOF 晚期融合	80.03%	+1.14 pp	95% CI [−1.00, +3.41]
1000	内容基线	82.29%	基准	–
1000	结构化解释直接拼接	82.94%	+0.65 pp	–
1000	结构化解释 + OOF 晚期融合	83.82%	+1.53 pp	95% CI [−1.28, +4.34]

数据量和融合策略有价值，但“改成结构化提示”本身没有稳定胜过旧提示。400 条时旧解释 late fusion 最强；1,000 条时结构化 late fusion 相对内容基线提高 1.53 pp。

4.2 RoBERTa: compact explanation 与验证集融合

表 7 RoBERTa 三种子结果。1000 条 compact late fusion 的逐种子提升为 +0.154/ +0.746/ +0.401 pp。

训练量	输入/融合	Macro-F1 均值 ±SD	相对内容基线	判断
400	内容基线	84.90 ± 1.52%	基准	–
400	旧 Qwen 直接拼接	82.57 ± 0.67%	−2.34 pp	退化
400	结构化解释直接拼接	82.44 ± 1.66%	−2.46 pp	退化
400	compact 直接拼接	84.30 ± 1.75%	−0.60 pp	基本追回
400	compact late fusion	84.88 ± 0.61%	−0.03 pp	种子方向不一致
1000	内容基线	87.19 ± 0.53%	基准	–
1000	结构化解释直接拼接	86.73 ± 1.12%	−0.46 pp	仍退化
1000	compact 直接拼接	87.21 ± 0.51%	+0.02 pp	接近持平
1000	compact late fusion	87.63 ± 0.29%	+0.43 pp	三个种子均为正

RoBERTa 对噪声解释敏感。长解释直接拼接会破坏内容信号；缩短解释并改为 late fusion 后，1,000 条训练下得到小幅且三个种子同方向的提升，但 $n = 3$ 仍不足以声称统计显著。




图 3 内部改进总览：TF-IDF、RoBERTa 与额外计算开销。误差线定义见原实验记录。

4.3 与原论文 Fig.6 的对应方式

表 8 原论文 Fig.6 与本地内部消融的概念映射。绝对值不作横向胜负比较。

实验	F1/Macro-F1	组件变化	比较边界
原论文完整 SPT-RII	78.3%	–	同一 SPT-RII 框架
原论文 –explanations	74.0%	–4.3 pp	证明解释模块重要
原论文 –update	75.5%	–2.8 pp	证明动态更新重要
本地 TF-IDF 1000 late fusion	83.82%	+1.53 ppvs 本地内容	不同模型/测试子集
本地 RoBERTa 1000 compact late fusion	87.63 $\pm$ 0.29%	+0.43 ppvs 本地内容	不同模型/测试子集

5 不确定性门控：对应 §6.7 / Table 6，仅概念对照

原论文 Table 6 比较了 10-shot LLM、1,000 样本 PEFT 与 SPT-RII。本地问题不同：不是让 Qwen 全量替代分类器，而是只处理基础模型置信度落在 $[0.28, 0.72]$ 的样本。阈值只在 200 条验证集上选择，测试集只评估一次。

表 9 不确定性门控结果。提升区间跨 0，因此属于探索性证据。

方法	Macro-F1	测试数	Qwen 覆盖	相对基线
TF-IDF 基线	82.29%	400	0%	基准
Qwen 直接分类	74.70%	400	100%	单独使用更差
不确定性门控	83.71%	400	38.5%	+1.42 pp; 95% CI $[-2.61, +5.37]$

154 条被路由样本上，Qwen 纠正 33 个基线错误，同时破坏 28 个原本正确样本，净增 5 条正确预测。混淆矩阵从 $[[120, 37], [30, 213]]$ 变为 $[[125, 32], [30, 213]]$ ，主要减少 5 个负类被误报为正类的错误。




图 4 不确定性门控：验证集选阈值，固定测试集一次评估。

为什么不能与 Table 6 直接相减

论文 Table 6 的大模型行是另一套 few-shot/PEFT 条件；本地门控只在 400 条子集上评估，还把 TF-IDF 与 Qwen 组合。83.71% 不能写成“比论文 SPT-RII 78.32% 高 5.39 pp”。

6 效率：对应 §6.10 / Table 9 / p.17

表 10 原论文 Table 9 与本地生成开销。硬件、量化、计时范围和任务均不同。

来源	模型	报告 F1	时间	硬件	任务含义
论文	Llama3.1-8B	75.79%	257 ms/条	RTX 4090	作为 SPT-RII 解释器
论文	Qwen2.5-7B	76.74%	283 ms/条	RTX 4090	作为 SPT-RII 解释器
论文	Deepseek-V3	78.32%	985 ms/条	未单列	远程/大模型设置
论文	ChatGPT-3.5	79.09%	1072 ms/条	服务端	远程 API
论文	ChatGPT-4o	78.60%	1062 ms/条	服务端	远程 API
本地	Qwen3-8B Q4	非同一 F1	562 ms/条	RTX 4060 8 GB	800 条墙钟 450.2 s；峰值 6.40 GiB

原论文 Table 9 测的是“更换 SPT-RII 解释生成模型后的整体 F1 和单条时间”；本地 0.562 s/条只统计 Qwen3-8B Q4 的解释生成。原论文 Fig.7 还明确排除了 LLM 解释开销。因此这里只能证明 RTX 4060 可以跑通该组件并量化成本，不能得出速度优越性结论。

7 如何通俗解释这次提升

30 秒讲法

直播弹幕通常只有几个字，单看一句很容易理解错。我们的做法不是让大模型包办分类，而是让它先把上下文压缩成一句更清楚的提示，再由小模型判断；遇到小模型拿不准的样本，才让大模型提供第二意见。公平地按单次 70-shot/类比较，我们是 78.00%，论文是 79.23%，还差 1.23 个百分点；把三个不同抽样的模型做概率集成后可以到 81.65%，但三个模型合起来看过 420 条训练样本，所以这是更强的工程组合，不是同预算单模型超过论文。




图 5 面向汇报的通俗对照图。a，同等单次样本预算下，本地独立运行仍略低于原论文；b，70-shot 工程集成点更高，但三个成员重新抽样，累计训练并集达到 420 条；c，三种内部改进均为正向点估计，但 TF-IDF 与门控的 95% CI 跨 0，RoBERTa 只有三个种子且没有正式 CI。

7.1 按图讲三句话

1. **先讲公平比较。**看图 5a: 每次训练使用同等级的少量标注时, 本地结果随着 50/60/70-shot 增加而接近论文, 但 70-shot 独立均值仍低 1.23 pp。这说明我们已经缩小差距, 但还不能说完成了同预算超越。
2. **再讲工程上为什么能更高。**看图 5b: 三个模型各自从不同样本训练, 再平均预测概率, 结果从 78.00% 提高到 81.65%。这类似让三个各自看过不同练习题的判断器共同表决, 稳定性更好; 代价是它们累计看过更多标注样本。
3. **最后讲真正改了什么。**看图 5c: 不再把长解释硬塞进分类器, 而是把“原弹幕”和“解释”分开学习、在验证集上决定如何融合; 同时只把难例交给 Qwen。TF-IDF、RoBERTa 和门控的点估计分别提高 1.53、0.43 和 1.42 pp, 但现有样本量还不足以把它们都称为统计显著提升。

最容易讲错的地方

不建议说: “我们的 70-shot 模型达到 81.65%, 超过原论文 79.23%。”

建议说: “同预算的 70-shot 独立运行是 78.00%, 距离论文 79.23% 还有 1.23 个百分点; 三模型工程集成达到 81.65%, 但累计训练样本并集扩大到 420 条, 因此它展示的是工程组合潜力, 而不是同预算单模型胜出。”

7.2 老师追问时的简短回答

问: 为什么不能直接拿 83.82% 或 87.63% 与论文的 79.23% 比?

答: 因为它们来自 1,000 条训练、400 条测试的内部实验, 测试样本和训练预算都不同。只有完整 9,069 条测试集上的 50/60/70-shot 实验最接近论文 Table 5。

问: 这些提升算不算已经证明有效?

答: 目前只能说点估计向好。TF-IDF 和门控的 95% CI 都跨 0; RoBERTa 虽然三个种子都提高, 但只有三个种子且没有正式 CI, 需要扩大实验。

问: 这次工作最有价值的地方是什么?

答: 在 4060 上把“解释压缩、分通道融合、难例路由、工程集成”完整跑通, 并把哪些结果能与论文比较、哪些只能内部比较分清楚, 为下一轮完整测试提供了可靠起点。

8 可信度、限制与下一步

8.1 目前可以成立的结论

- 低成本系统已跑通，主结果均有固定测试集、验证集选参或 OOF 选参记录。
- 70-shot 独立运行均值距离原论文 1.23 pp；工程集成点达到 81.65%，但预算边界已单独披露。
- 1,000 条训练时，TF-IDF late fusion 提高 1.53 pp；RoBERTa compact late fusion 提高 0.43 pp，三个种子方向一致。
- 门控证明“只让大模型处理难例”比全量直接分类更合理，但 400 条测试上的置信区间跨 0。

8.2 不能忽略的限制

表 11 结果解释所需的边界条件。

风险	事实	文档处理
指标定义	论文未明确 F1 averaging；本地用 Macro-F1	所有跨论文差值标为近似口径
方法完整性	未实现 soft prompt、BiLSTM、动态 verbalizer	称为低成本替代，不称完整复现
集成预算	不同种子重新抽样；70-shot 三模型训练并集 420	集成点与独立均值分列
同直播间相关性	12 个 live_id 同时出现在训练/测试	尚未证明跨直播间泛化
上下文 split	解释实验中 81% 训练、99.5% 测试含跨 split 上下文	无金标泄漏，但含转导式同流信息
统计功效	内部测试 $n = 400$ ；RoBERTa 仅 3 个种子	不把小幅变化写成显著提升

8.3 下一轮优先实验

1. 将门控扩展到 9,069 条完整固定测试集，报告调用率、时间和 paired bootstrap CI。
2. 固定同一 70-shot/类训练集做 5–10 次初始化集成，把纯模型集成收益与扩大样本并集收益分开。
3. 按 live_id 分组划分并只用 split 内上下文，测试真正的跨直播间泛化。
4. 系统扫描窗口 $k \in \{0, 5, 10, 20\}$ 与解释长度，直接对应原论文 Fig.9。

最终判断

这次提升是成功的工程进展，但不是已完成的 SPT-RII 同预算复现。稳妥表述是：本地替代路线进一步缩小了与论文结果的距离，并给出一个更高的工程集成点；下一步需要控制累计标注预算和直播间划分，才能形成更强的研究结论。

9 证据文件索引

以下路径对应本文全部数字和原文位置。source_map.json 提供 S/T 锚点，CSV/JSON 文件提供本地逐种子、融合和门控证据。

原论文 PDF	E:\zotero\storage\7DATFQRR\Zhu 等-2026-Analyzingbulletchatsforrecommenda tionintentidentificationDatasetandmethod.pdf
原文位置映射	E:\Lab\experiment\paper_reader\source_map.json
Table 5 原图	E:\Lab\experiment\paper_reader\assets\table5_recdy.png
协议清单	E:\Lab\experiment\results\paper_comparison\paper_matched_manifest.json
Table 5 对比	E:\Lab\experiment\results\paper_comparison\paper_vs_local_comparison.csv
逐种子来源	E:\Lab\experiment\results\paper_comparison\paper_matched_per_seed_source .csv
TF-IDF 改进	E:\Lab\experiment\results\improvement\classical_improvement_summary.csv
配对区间	E:\Lab\experiment\results\improvement\improvement_comparisons.csv
RoBERTa 改进	E:\Lab\experiment\results\improvement\roberta_improvement_summary.csv
RoBERTa 配对	E:\Lab\experiment\results\improvement\roberta_improvement_paired.csv
不确定性门控	E:\Lab\experiment\results\improvement\uncertainty_gate.json
门控逐行预测	E:\Lab\experiment\results\improvement\uncertainty_gate_test_predictions. csv
完整实验报告	E:\Lab\experiment\report\report.pdf